데이터사이언스를위한지식관리시스템

14주차: Airflow(Workflow Management)

Airflow

- 워크플로우 관리도구 입니다
- 데이터 파이프라인, 배치 작업, ETL 등 반복적/복잡한 작업 흐름 관리
- 하나의 워크플로우를 DAG라는 것으로 정의하여 관리합니다
- 스케줄링 기반의 트리거, 온디맨드 트리거, 이벤트 기반의 트리거를 지원합니다
- Airflow의 히스토리: https://airflow.apache.org/docs/apache-airflow/stable/project.html
- 2025년 현재의 Airflow는 3.x 입니다
- Airflow 3.0이 2025년에 릴리즈 되면서 UI에 많은 변화가 있었고 향상된 사용자 경험을 제공하게 됩니다

DAG

- 방향성이 있고 순환이 없는 그래프 입니다
- 즉, 작업의 시작과 끝이 있는 워크플로우를 의미합니다
- 이것이 Airflow에서는 하나의 실행 단위가 됩니다
- DAG 내에서는 task들이 있고 이들이 방향성을 갖고 연결됩니다
- 그 연결에는 순환이 없어야 합니다

Airflow Vs Cron

- Cron이라는 스케줄러를 이미 배웠는데 Airflow를 다시 하는 이유입니다
- Cron은 스케줄이 되면 무조건 실행합니다 -> 중복/충돌 가능합니다
- 이를 방지하기 위해 pid파일을 남기는 방식도 고려해 보았지만 빈틈은 있습니다
- Airflow는 DAG + Scheduler로 Task 순서를 보장, 중복 방지하는 메커니즘을 제공합니다

Airflow의 설치

- Airflow 3.1.3은 pip를 이용하여 간편하게 설치할 수 있습니다
- https://airflow.apache.org/docs/apache-airflow/stable/installation/installing-from-pypi.html 를 참고하여 설치합니다
- WSL 또는 클라우드 환경에서 사용 가능하며 개별 인스턴스로 설치, 구동이 가능하니 개별 계정으로 모두 개별 설치를 진행해보겠습니다
- 설치 후 airflow 라고 실행해봅니다
- 오른쪽과 같이 나오면 설치가 된 것입니다

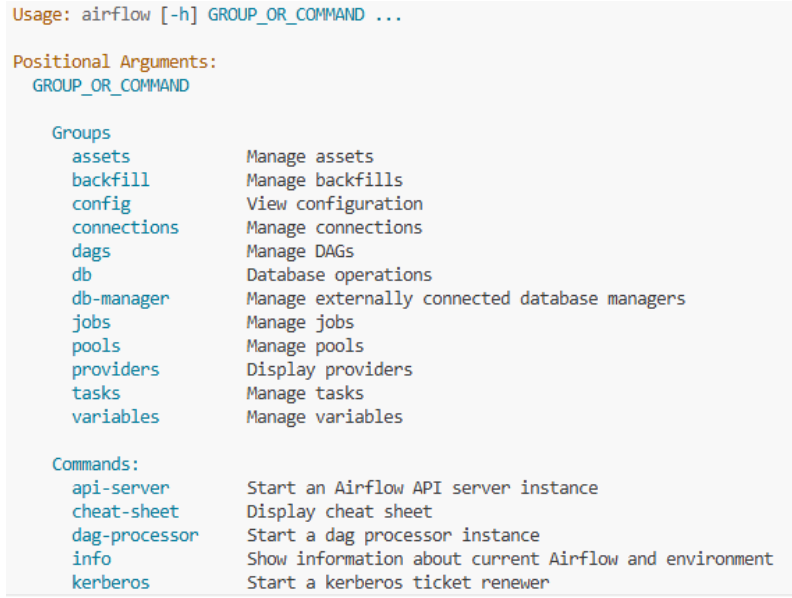

Airflow의 프로세스 구성요소

- API server (실행명령: airflow api-server --port 포트번호)
- 주의사항: api-server 구동시에 port번호를 다르게 구성하겠습니다
- 충돌 방지를 위해 port번호는 user계정의 번호와 동일하게 하겠습니다

```
(base) ubuntu@uos-bigdata:~$ airflow api-server --port 8022

Please confirm database initialize (or wait 4 seconds to skip it). Are you sure? [y/N]
2025-12-05T22:07:30.961704Z [info     ] Log template table does not exist (added in 2.3.
  ____________       _____________
 ____    |__( )_________  __/__  /________      __
____  /| |_  /__  ___/_  /_ __  /_  __ \_ | /| / /
___  ___ |  / _  /   _  __/ _  / / /_/ /_ |/ |/ /
 _/_/  |_/_/  /_/    /_/    /_/  \____/____/|__/
2025-12-05T22:07:30.974485Z [info     ] Running the uvicorn with:
Apps: all
Workers: 1
Host: 0.0.0.0:8022
Timeout: 120
Logfiles: -
```

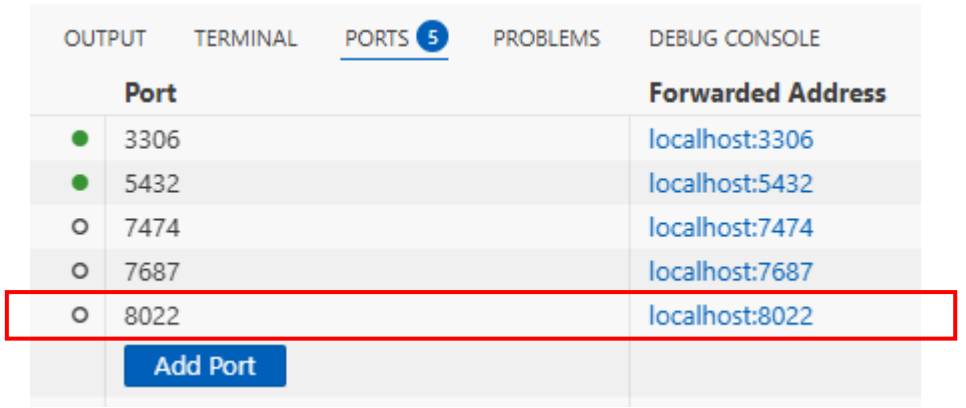

터널링도 잊지 않고 해줍니다

Airflow의 프로세스 구성요소

- DAG processor (실행명령: airflow dag-processor)
- Scheduler (실행명령: 아래 실행명령에서 복사하여 포트번호를 바꿉니다)
- Scheduler의 포트번호는 각자 할당된 번호로 뒤의 2자리를 바꿉니다
- 주의사항: foreground모드로 돌기 때문에 터미널을 별도로 띄워서 진행합니다

```
export AIRFLOW__LOGGING__WORKER_LOG_SERVER_PORT=8722
airflow scheduler
```

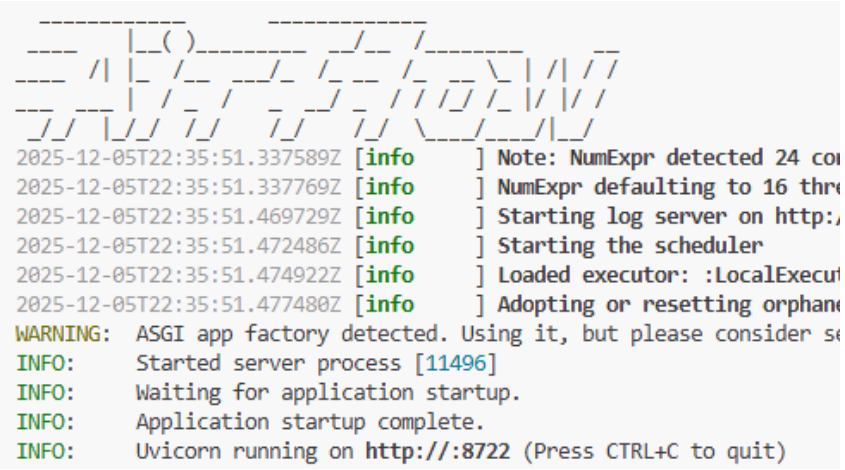

Airflow의 사용자 UI 접속

- 기본 8080 포트를 사용하나 각자 변경하신 포트로 접속합니다
- http://localhost:<각자의포트번호>
- 사용자명은 admin 입니다
- 패스워드는 아래의 경로에서 확인할 수 있습니다
- 이제부터는 별도 첨부된 ipynb파일을 사용합니다
- 각 코드셀에 있는 내용을 py 파일로 만들면서 DAG를 만들 것입니다

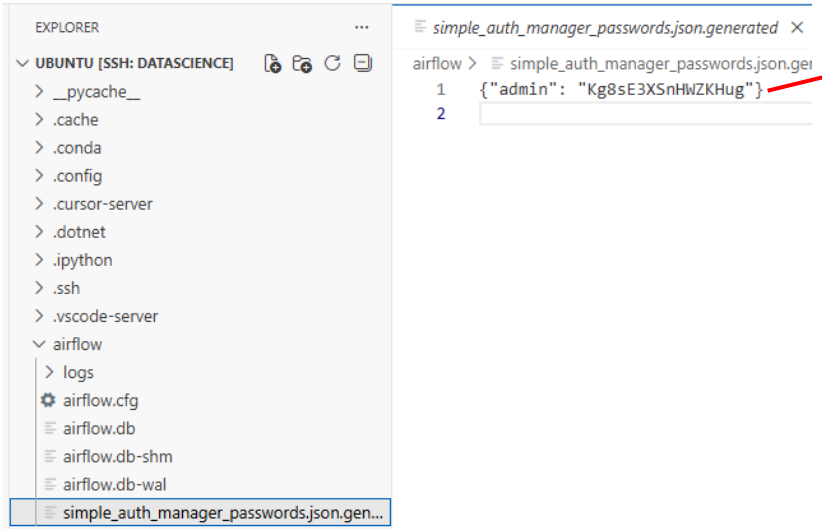

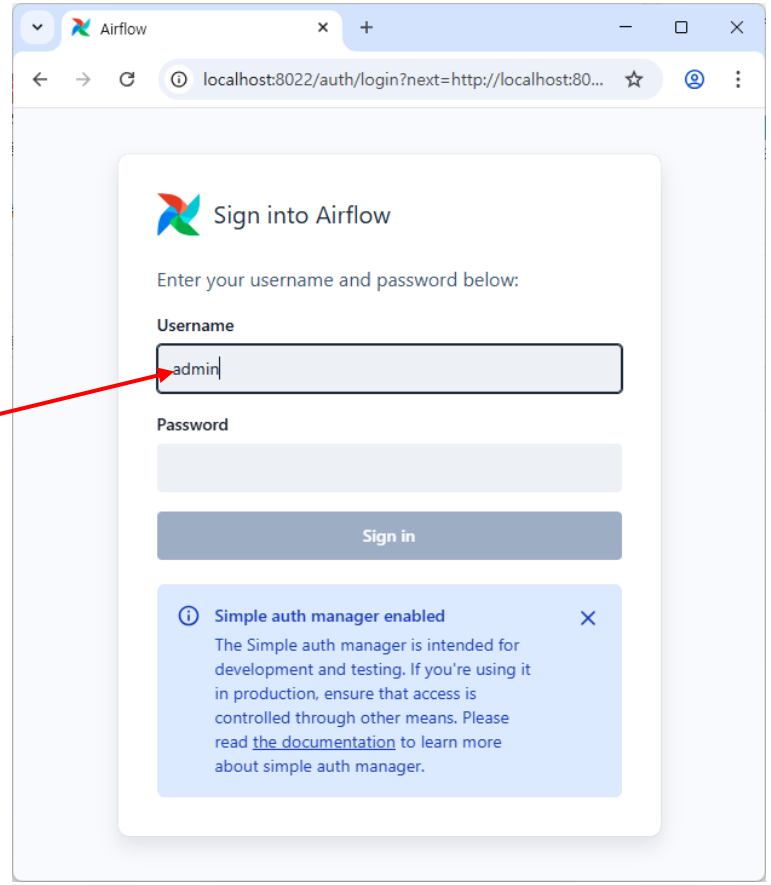

DAG 등록

- 1개의 task로 등록된 DAG를 등록해보겠습니다
- 샘플코드는 Airflow UI에 연결하여 찾을 수 있습니다
- 우선 py파일을 DAG로 등록하는 위치는 오른쪽과 같습니다
- airflow라는 디렉토리는 만들어졌을 것입니다
- 그 아래에 dags라는 디렉토리를 만듭니다
- dags 디렉토리에 py파일을 만들 것입니다
- 이제부터 그 py파일을 만드는 방법을 알아보겠습니다

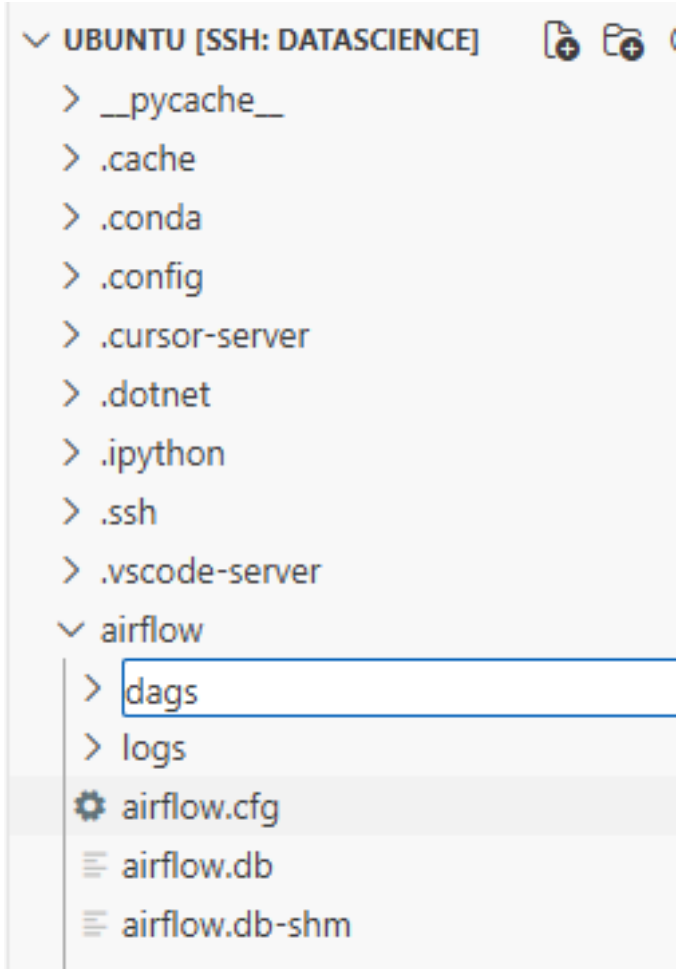

Airflow의 Sample DAG들

- 아래와 같이 Dags탭을 확인합니다
- 80개의 샘플 DAG들이 등록되어 있습니다
- 하나를 클릭하면 아래 오른쪽과 같이 DAG의 상세 화면을 볼 수 있고 코드 탭이 있습니다

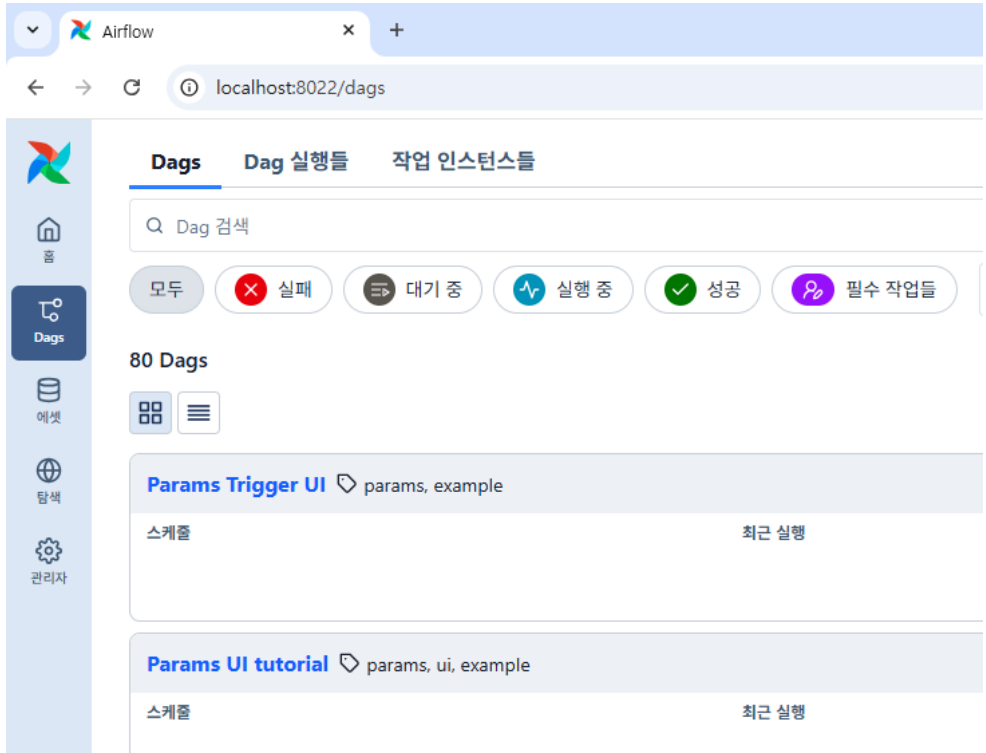

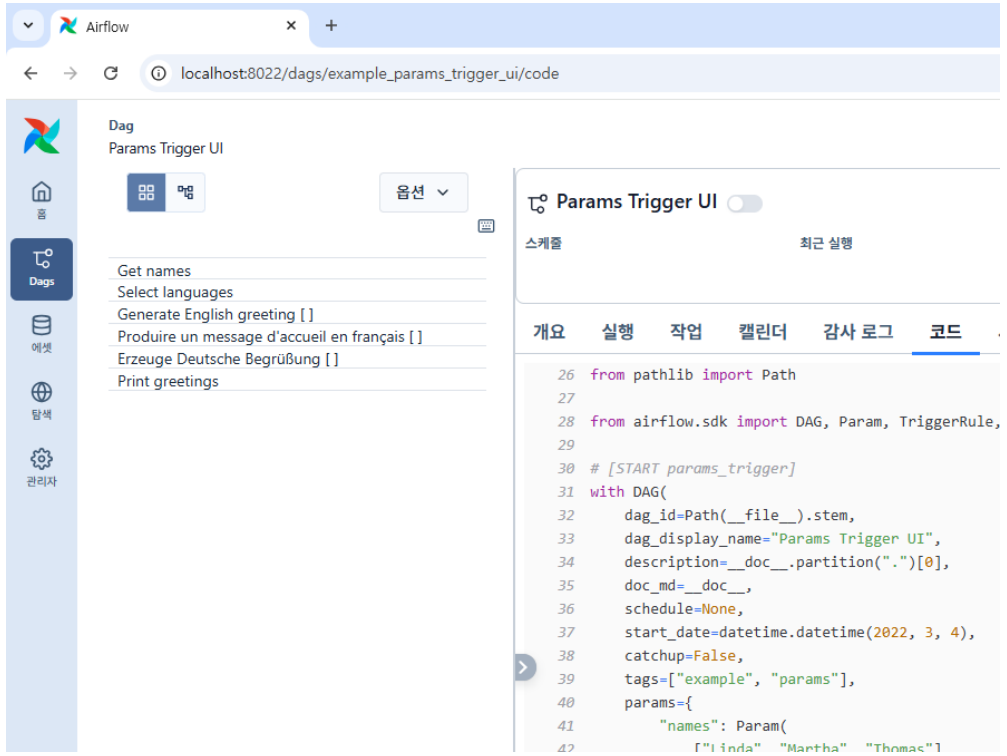

Operator

- Dags탭에서 example_python_operator 를 검색해보겠습니다
- 그리고 해당 DAG의 코드탭에 진입합니다
- 아래 그림을 보고 코드를 따라 타이핑 하시는 것보다는 UI에 있는 코드 탭을 참조하여 아래 그림과 같은 코드가 있는 부분을 찾아봅니다

```
with DAG(
    dag_id="example_python_operator",
    schedule=None,
    start_date=pendulum.datetime(2021, 1, 1, tz="UTC"),
    catchup=False,
    tags=["example"],
) as dag:
    # [START howto_operator_python]
    def print_context(ds=None, **kwargs):
        """Print the Airflow context and ds variable from the context."""
        print("::group::All kwargs")
        pprint(kwargs)
        print("::endgroup::")
        print("::group::Context variable ds")
        print(ds)
        print("::endgroup::")
        return "Whatever you return gets printed in the logs"

    run_this = PythonOperator(task_id="print_the_context", python_callable=print_context)
    # [END howto_operator_python]
```

task

- 이렇게 PythonOperator들로 선언된 변수가 있습니다
- 이들을 task라고 합니다
- 각 task를 >> 로 연결합니다

```
run_this = PythonOperator(task_id="print_the_context", python_callable=print_context)
# [END howto_operator_python]

# [START howto_operator_python_render_sql]
def log_sql(**kwargs):
    log.info("Python task decorator query: %s", str(kwargs["templates_dict"]["query"]))

log_the_sql = PythonOperator(
    task_id="log_sql_query",
    python_callable=log_sql,
    templates_dict={"query": "sql/sample.sql"},
    templates_exts=[".sql"],
)
# [END howto_operator_python_render_sql]

# [START howto_operator_python_kwargs]
# Generate 5 sleeping tasks, sleeping from 0.0 to 0.4 seconds respectively
def my_sleeping_function(random_base):
    """This is a function that will run within the DAG execution"""
    time.sleep(random_base)

for i in range(5):
    sleeping_task = PythonOperator(
        task_id=f"sleep_for_{i}", python_callable=my_sleeping_function, op_kwargs={"random_base": i / 10}
    )

    run_this >> log_the_sql >> sleeping_task
```